

标题	AlphaFold2 技术精读
英文原题	Highly accurate protein structure prediction with AlphaFold
作者/主体	John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool 等, DeepMind
发表/来源	Nature 596, 583–589 (2021)
DOI/标识	10.1038/s41586-021-03819-2
原文链接	https://www.nature.com/articles/s41586-021-03819-2
开放获取	是 (CC-BY 4.0)
整理日期	2026-06-24

AlphaFold2 技术精读

AlphaFold2 是首个能仅凭氨基酸序列、在多数情况下以接近实验精度 (CASP14 域 GDT_TS 中位数约 92.4) 端到端预测蛋白质三维结构的深度学习系统, 标志着 50 年「蛋白质折叠问题」中单链结构预测部分取得突破。

关于来源的说明: 本精读所引数据均来自整理者实际检索到的公开来源 (见文末「参考来源」)。受本次运行环境的网络出口策略限制, 无法对 Nature 原文与 PMC 全文做逐字抓取, 部分表述为基于二手综述/官方培训材料的转述; 凡涉及精确数字处均标注来源, 无法在所抓资料中坐实的细节标注「待核实」。正式引用请以 Nature 原文为准。

1. 背景与动机

蛋白质折叠问题

蛋白质的功能由其三维结构决定, 而结构在很大程度上由氨基酸序列编码。「仅凭氨基酸序列预测蛋白质会折叠成的三维结构」——即「蛋白质折叠问题」中的结构预测部分——是一个已有 **50** 余年历史的开放性科学难题 (Anfinsen 假说指出序列决定结构)。

实验测定结构的主流手段 (X 射线晶体学、冷冻电镜、核磁共振 NMR) 昂贵、耗时, 导致已知序列数量 (数亿级, UniProt) 与已实验解析结构数量 (PDB 中约数十万条目) 之间存在巨大鸿沟。

CASP 与此前方法的局限

CASP (Critical Assessment of protein Structure Prediction) 是每两年举办一次的盲测竞赛: 组织方在结构尚未公开前发放序列, 各团队提交预测, 再与随后公布的实验结构比对, 是该领域公认的「黄金标准」评测。

在 AlphaFold2 之前: - 传统方法 (基于模板/同源建模、共进化耦合、物理能量函数等) 在 **缺乏近缘同源结构 (Free Modeling / FM 类)** 时精度远低于实验水平。 - DeepMind 的第一代 **AlphaFold (AlphaFold1)** 在 **CASP13 (2018)** 已取得当时参赛者中的最高精度, 但仍未达实验级; 其思路更

接近「先预测残基间距离分布，再用梯度下降优化结构」的两阶段范式。 - AlphaFold2 是 完全重新设计的模型（在 CASP14 以队名「AlphaFold2」参赛，与 CASP13 版本是不同的系统）。

CASP14 突破

- **CASP14** 评测期约为 **2020 年 5-7 月**，结果于 **2020 年 12 月** 的会议上公布。
- AlphaFold 预测的 域 **GDT_TS** 中位数达到约 **92.4**，这是 CASP 历史上首次达到这一平均精度水平，尤其是在更困难的 Free Modeling 目标上。
- 据报道，其精度「在多数情况下可与实验结构相媲美」（accuracy competitive with experimental structures），并大幅超越其他方法。
- CASP14 评估方按 z 分数加总排名中，AlphaFold2 得分 **244.0**，而第二名团队约为 **90.8**，差距悬殊。
- CASP 组织者 John Moult 在闭幕发言中表示「单链蛋白质的结构预测问题现在已经解决」。学界（如 Mohammed AlQuraishi）普遍认为这是范式级突破，剩余改进更偏「工程问题」而非「科学问题」；但也有声音强调「折叠问题」（含动力学、复合物、构象变化）尚未全部解决。

注：GDT_TS (Global Distance Test - Total Score) 取值 0-100，越高越好；一般认为 **GDT_TS $\geq$ 90** 即可视为与实验结构相当。

2. 核心架构

AlphaFold2 是一个 端到端 (**end-to-end**) 神经网络：输入氨基酸序列、由其检索得到的 多序列比对 (**MSA**) 以及 结构模板 (**templates**)，直接输出全原子三维坐标，无需传统的「先预测约束、再单独优化」两阶段流程。

整体数据流可分为三段：输入特征构建 → **Evoformer 主干** → **Structure Module** (结构模块)，并辅以 **recycling** (循环迭代) 包裹整个网络。

2.1 输入：MSA 与模板，两类核心表示

网络内部维护两种「富表示」并反复精炼： - **MSA 表示 (MSA representation)**：刻画目标序列与其同源序列之间的关系，承载共进化信息（哪些残基位点共同变异，暗示空间上接触）。 - **配对表示 (pair representation)**：一个以残基对为单位的二维表示，描述序列中每个氨基酸与其他每个氨基酸之间的关系（可理解为「残基间关系图」的边特征）。

模板结构信息也被编码进这两类表示中。

2.2 Evoformer 主干

Evoformer 是 AlphaFold2 的核心模块，包含 **48 个** (权重不共享的) **block** 堆叠（数量据二手资料，待与原文核实）。每个 block 含两条「塔」——MSA 塔与配对 (pair) 塔——并设计了二者之间的 双向通信机制，让序列层面的共进化信息与残基对的几何关系信息不断互相更新：

- **轴向注意力 (axial attention)**：在 MSA 表示这样的二维网格上，分别沿「行 (row-wise)」和「列 (column-wise)」做注意力，从而高效处理大矩阵。
- **MSA → pair 的信息传递**：MSA 列方向的统计（如成对相关）被汇总写入配对表示。

- 配对表示的三角更新 (**triangular updates**) 与三角自注意力 (**triangular self-attention**)：这是 Evoformer 的标志性设计，用以注入 三角不等式 (**triangle inequality**) 这一几何先验——任意三个残基 i 、 j 、 k 的两两距离需满足三角约束。具体含两类块：
- 三角乘法更新 (**triangle multiplicative update**)：分「起点 (starting node)」与「终点 (ending node)」两个版本，基于共享同一起点/终点的所有边来更新边 (i,j)。
- 三角自注意力 (**triangle self-attention**)：同样有「环绕起点 / 环绕终点」两个版本。
- 门控、残差连接、转移 (**transition**) 层 等标准组件。

经过 Evoformer 反复精炼后，配对表示已隐含残基间的几何关系，MSA 表示的「第一行」（对应目标序列）成为送入结构模块的 单一表示 (**single representation**)。

2.3 Structure Module 与 Invariant Point Attention (IPA)

结构模块 (Structure Module) 将抽象表示「翻译」为显式三维坐标：

- 残基气体 / 刚体框架表示 (**residue gas / backbone frames**)：每个残基的主链被表示为一个独立的刚体局部坐标系（一个旋转 + 平移，即 3D 框架），初始时所有残基都放在原点（故称「residue gas」），随后被逐步移动、旋转到正确的相对位置。
- 结构模块约含 **8** 个权重共享的层（数量据二手资料，待核实）。每一层都用 不变点注意力 (**Invariant Point Attention, IPA**) 来更新单一表示与主链框架。
- **IPA** 的关键性质——对全局刚体变换不变：它是一种「几何感知」的注意力。除常规的基于内容的自注意力外，IPA 还：1. 将配对表示转化为逐元素的 **pair bias** (配对偏置) 加入注意力；2. 引入定义在三维空间中的「点」，计算残基框架之间的 距离亲和度 (**distance affinities**)。由于这些点在各自残基的局部坐标系中定义，整套注意力对蛋白质整体的平移/旋转 不变。
- 之后结构模块预测 主链与侧链的扭转角 (**torsion angles**)，结合主链框架即可重建 全原子坐标。
- 训练用 **FAPE** 损失 (**Frame-Aligned Point Error**, 框架对齐点误差)：在每个残基的局部框架下比较预测与真实原子位置，强调局部结构准确性，并天然对全局刚体变换不变。

直观理解：Evoformer 负责「读懂」序列/共进化/几何关系，Structure Module 负责把这种理解「摆」成真实可见的 3D 坐标，IPA 则保证「摆」的过程不依赖于你从哪个角度看蛋白质。

3. 训练与推理技巧

3.1 Recycling (循环迭代精炼)

整个网络 (Evoformer + Structure Module) 被外层 **recycling** 包裹：把前一轮的输出作为额外输入再喂回网络，重复若干次（论文默认 **3** 次循环，对应共 **4** 趟前向）。被回收的内容包括：结构模块输出的 主链原子坐标、Evoformer 输出的 配对表示 以及 **MSA** 表示的第一行。- 作用：在 几乎不增加参数数量 的情况下让网络「更深」，对输入做多轮迭代精炼，显著提升精度。

3.2 Self-distillation (自蒸馏，利用未标注序列)

为突破已知实验结构 (PDB) 数量的限制，AlphaFold2 采用类似 **noisy-student** 自蒸馏 的半监督策略：1. 先用 PDB 训练一个「教师」网络；2. 用它去 预测大量未标注序列的结构（例如从 Uniclust30

取约 **35 万** 条多样序列)，并按置信度筛出高置信子集，构成新的「预测结构数据集」；3. 再用 **PDB + 该自蒸馏数据集** 联合训练新模型。据二手资料，训练样本中约 **25%** 来自 **PDB** 已知结构、约 **75%** 来自自蒸馏预测结构（比例待与原文核实）。- 训练时对学生注入噪声（dropout 等）以增强泛化。- 关联的序列数据库包括 Uniref90、Uniclust30、MGnify，以及 DeepMind 为此构建的 **BFD (Big Fantastic Database)**，约 **22 亿** 条序列）。

3.3 置信度预测：pLDDT 与 PAE / pTM

模型在输出结构的同时给出自我置信度估计，这是其极具实用价值的一点：- **pLDDT (predicted LDDT, 预测的局部距离差异检验)**：逐残基的局部置信度（0-100），衡量该残基局部结构与真实结构吻合的把握。常用阈值参考：>90 很高、70-90 较好、50-70 较低、<50 很可能是无序/不可靠区。pLDDT 与「内在无序区」高度相关，因而也被当作无序预测工具。- **PAE (Predicted Aligned Error, 预测对齐误差)**：残基对级别的 **全局** 置信度——「若以残基 Y 对齐预测与真实结构，则残基 X 的预期位置误差是多少埃 (Å)」。**PAE** 低表示两残基（或两个结构域）的相对位置可信，常用于判断 **域间排布 / 复合物界面** 是否可靠。- **pTM (predicted TM-score, 预测的模板建模得分)**：对整体结构的 TM-score 的估计（衡量整体折叠相似度），pTM 由 PAE 相关量推导；pTM > 0.5 通常意味着整体折叠大致正确。

4. 关键结果与数据

下表数据均来自实际检索到的来源；标「待核实」者未能在所抓资料中坐实精确值。

指标	数值	说明 / 来源
CASP14 域 GDT_TS 中位数	约 92.4	CASP 史上首次达此平均精度 (Wikipedia / 多源综述)
高精度域占比 (best-of-5)	87 / 92 域 GDT_TS > 70	二手综述
达实验级精度域 (best-of-5)	58 域 GDT_TS > 90	二手综述
主链 RMSD (结构化区域)	典型 约 1.2-1.6 Å	二手综述（与原文 r.m.s.d.95 指标的精确对应关系待核实）
CASP14 z 分数加总排名	AlphaFold2 244.0 vs 次优 90.8	二手综述
「实验级」阈值参考	GDT_TS ≥ 90	领域共识
Evoformer block 数	48 (权重不共享)	二手资料，待与原文核实
Structure Module 层数	8 (权重共享)	二手资料，待与原文核实
Recycling 次数	3 次	二手资料，待与原文核实

说明：原文衡量主链精度常用 **r.m.s.d.95**（在 95% 残基上对齐后的 C α RMSD）、全原子精度用侧链 RMSD 等指标。常被引用的「主链 r.m.s.d.95 中位数约 0.96 Å、全原子约 1.5 Å」未能在本次所抓资料中逐字坐实，故此处标注为待核实，请以 Nature 原文 Fig.1/正文为准。

5. 意义与影响

- 范式转变：把蛋白质结构预测从「精度远逊实验」推进到「多数情况下接近实验」，被广泛视为 AI for Science 的里程碑（John Jumper 与 Demis Hassabis 因 AlphaFold 与 David Baker 共享 **2024 年诺贝尔化学奖**——背景信息，非本论文内容）。
- **AlphaFold 蛋白质结构数据库 (AlphaFold Protein Structure Database, AlphaFold DB)**：DeepMind 与 **EMBL-EBI**（欧洲生物信息学研究所）合作建立的免费公开数据库（许可 **CC-BY 4.0**）。
- **2021 年 7 月** 首批发布 约 **35 万**（部分来源记为逾 **36 万**）个结构，覆盖人类蛋白组（约 2 万个人类基因编码蛋白）及 **20 个**模式生物蛋白组（序列取自 UniProt 2021_02）。
- **2022 年 7 月** 扩展至 逾 **2 亿** 个结构，几乎覆盖 UniProt 中已编目的全部蛋白序列。
- 数据库用 **pLDDT** 给结构着色以提示可信度；已被 190 多个国家、数百万用户使用。
- 下游应用：加速结构生物学、药物发现、酶工程、罕见病/疾病机理研究、宏基因组「暗物质」蛋白注释等；并催生 AlphaFold-Multimer、AlphaFold3、ESMFold、OpenFold、RoseTTAFold 等后续工作。
- 开源：DeepMind 于 **2021 年夏** 开源 AlphaFold v2 代码，并随论文发布约 60 页补充材料，极大降低了复现与二次开发门槛。

6. 局限与开放问题

AlphaFold2 强大但有明确边界（部分由原作者、部分由后续研究指出）：

- 以单链/单构象为主：默认预测 单条多肽链（单体）的 单一构象，AlphaFold DB 提供的也是单链模型而非生物学相关的复合物。原生 AF2 对 多链复合物 / 多聚体 (**multimer**) 支持有限（后由 AlphaFold-Multimer 改进）。
- 构象变化 / 动力学弱：通常只给一个静态构象，难以同时刻画 **apo/holo** 等多态、别构开关与动态过程；不直接输出系综或动力学。
- 无序区 (**IDR/IDP**)：对 内在无序区域 往往表示为「漂浮」的长延展环；不能预测本就不存在单一固定构象的区域——但 低 **pLDDT** 反而是无序的良好指示。
- 点突变效应不敏感：由于缺乏突变-结构/能量数据，且模型偏「学模式」而非「算物理力」，AF2 对 单点突变 引起的结构/稳定性变化往往不敏感，预测突变效应仅部分成功。
- 依赖 **MSA** 深度：对 缺乏同源序列（浅 **MSA**）的孤儿蛋白、人工设计序列等，精度可能下降。
- 不直接给出折叠机理/通路：预测的是终态结构，而非折叠过程；「折叠问题」的动力学与复杂体系层面仍属开放问题。
- 复杂体系（如膜蛋白）的不确定性通常会反映在 **PAE** 上，应结合置信度审慎使用。

7. 关键指标速查

项目	内容
论文	Jumper et al., Nature 596, 583–589 (2021) ; DOI 10.1038/s41586-021-03819-2
任务	序列 + MSA + 模板 → 全原子 3D 结构 (端到端)
核心模块	Evoformer (MSA + pair, 轴向注意力 + 三角更新/三角自注意力)
输出模块	Structure Module + IPA (不变点注意力), 残基刚体框架 → 坐标
主损失	FAPE (框架对齐点误差)
关键技巧	recycling (约 3 次)、self-distillation (noisy-student 半监督)、pLDDT、PAE/pTM
CASP14 成绩	域 GDT_TS 中位数 约 92.4 (实验级, 史上首次)
置信度	pLDDT (逐残基局部)、PAE (残基对/全局)、pTM (整体折叠)
数据库	AlphaFold DB (与 EMBL-EBI 合作, CC-BY 4.0) : 2021 约 35 万 → 2022 逾 2 亿结构
主要局限	单链/单构象、复合物/动力学/无序区/点突变较弱

参考来源

- [Highly accurate protein structure prediction with AlphaFold — Nature](#) — 原始论文 (CC-BY 4.0), 本精读的主依据; 本次环境无法直接抓取全文, 引用以此为准。
- [PMC 全文 PMC8371605](#) — 论文开放获取全文 (PubMed Central), 含摘要与方法 (本次环境出口策略限制无法直接抓取)。
- [AlphaFold — Wikipedia](#) — CASP14 背景、GDT_TS 92.4、时间线、AlphaFold DB 规模与局限。
- [AlphaFold2 @ CASP14 \(M. AlQuraishi 博客\)](#) — CASP14 现场反应与意义评述。
- [The AlphaFold2 Method Paper: A Fount of Good Ideas \(M. AlQuraishi\)](#) — 架构 (Evoformer/IPA/recycling) 深度解读。
- [How does DeepMind AlphaFold2 work? \(Boris Burkov\)](#) — Evoformer、三角注意力、IPA 技术细节。
- [AlphaFold 2 is here: what's behind the structure prediction miracle \(OPIG/blopig\)](#) — 自蒸馏、置信度等训练细节。
- [Strengths and limitations of AlphaFold 2 — EMBL-EBI Training](#) — 官方培训材料, 局限性权威表述。
- [Glossary of terms / Confidence scores — EMBL-EBI Training](#) — pLDDT、PAE、pTM 定义。
- [AlphaFold Protein Structure Database — EMBL-EBI 及 About](#) — 数据库规模、CC-BY 4.0 许可、pLDDT 着色。
- [AlphaFold DB: massively expanding structural coverage \(Nucleic Acids Res, PMC8728224\)](#) — 2021 年首发 36 万结构、20 个模式生物。
- [AlphaFold DB in 2024: over 214 million sequences \(Nucleic Acids Res\)](#) — 逾 2 亿结构扩展。

- [Applying and improving AlphaFold at CASP14 \(PMC9299164\)](#) — CASP14 应用与改进，z 分数、精度统计。
- [AlphaFold2 and its applications in biology and medicine \(Signal Transduct. Target. Ther.\)](#) — Evoformer/IPA/自蒸馏/recycling 综述。